ObservaStage

Valoriser et suivre les données de stages de Polytech Lille

Augustin Mélon · IS5 ISIA · Projet ingénieur 2026-2027

Soutenance intermédiaire · 21 octobre 2026

Référente : Dorothée Bernard (Direction des Relations Entreprises)

Tutrice école : Marie-Éléonore Kessaci · Expert technique : Bastien Cazaux



CONTEXTE

Des données de stages riches… mais inexploitables

- La **Direction des Relations Entreprises** gère les conventions de stage de **toutes les formations** (PEIP, licences, masters, cycle ingénieur)
- Depuis 2025-2026, tout passe par **EsupStage**, l'outil national de gestion des conventions
- EsupStage gère une convention… mais **n'analyse pas l'ensemble** : la seule sortie est un fichier Excel de 71 colonnes par année
- Bénéficiaires potentiels : direction (indicateurs, contrôles), enseignants (thématiques), futurs stagiaires (structures d'accueil)

80 %

des questions posées à la DRE sur les stages restent **sans réponse**

30 min

de traitement manuel pour chaque extraction, pour les autres

1 053

conventions en 2025-2026 · une seule personne pour les gérer

OBJECTIF

Un outil pour importer, contrôler, structurer et explorer

Importer
le fichier EsupStage de l'année

›

Contrôler
signaler les données incohérentes

›

Structurer
une base de données historisée

›

Explorer
indicateurs, recherche, export

Utilisatrice de la V1

Dorothée Bernard (DRE), **non informaticienne**. Elle doit pouvoir importer chaque année sans aide.

Plus tard : enseignants, étudiants (avec des droits adaptés).

La difficulté centrale

Le format de l'extraction **change d'une année à l'autre** : colonnes renommées, déplacées, ajoutées, supprimées.

→ **L'import doit s'adapter sans modifier le code.**

Exemples de questions posées à la DRE

- Quelle est la durée moyenne des stages de 4A ?
- Combien de stages à l'étranger, et dans quels pays ?
- Quelle part des stages en Hauts-de-France ?
- Combien de stages dans la recherche ?
- Quelles structures accueillent nos étudiants en génie civil ?
- Quelles expériences (CDD, intérim) en PEIP et 3A ?

LES DONNÉES

Pourquoi un import « naïf » ne suffit pas

Des intitulés trompeurs

Tirets, apostrophes et casse varient dans un même fichier :

`Service d'accueil - Commune` `Service d’accueil – Adresse`

« Code NAF » contient… un libellé :

`Ingénierie, études techniques`

Des informations à dériver

Pas de colonne niveau, région, secteur ou recherche. Le niveau et la spécialité sont fusionnés :

`2an Ing Polytech Génie civil` → `4A · Génie civil`

Table de correspondance construite pour les 48 codes étape

Une qualité hétérogène

- **18 %** de cellules vides, 7 colonnes entièrement vides
- SIRET absent pour **21 %** des structures (étranger)
- Valeurs aberrantes : jusqu'à **175 h** par semaine

Aucun historique

2025-2026 est la **première année** d'EsupStage : impossible de tester l'évolution des colonnes sur des données réelles.

→ fichiers de test modifiés à partir de la base réelle

CAHIER DES CHARGES

Périmètre de la V1, validé avec la DRE le 12/10

Indispensable	Import avec **mapping configurable** et profil réutilisable · contrôles et rapport d'anomalies · indicateurs (durée en jours, semaines et heures ; France / étranger ; Hauts-de-France ; par niveau, spécialité, année) · recherche multicritère · **export CSV et XLS**
Souhaitable	Historique multi-années · recherche plein texte · graphiques · rapprochement des structures sans SIRET
Bonus	Indicateurs « recherche » et « secteur » · type d'expérience (CDD, intérim, bénévolat)
Hors V1	Gratification · gestion de plusieurs profils

Critères de validation (proposés)

1. **Import** autonome, adapté aux colonnes modifiées, sans doublon au réimport
2. **Indicateurs** identiques aux chiffres de référence
3. **Recherche** par année, niveau, spécialité, lieu, thématique
4. **Export** CSV et XLS lisible dans Excel

Contraintes : stack imposée (PHP, JavaScript, PostgreSQL) · RGPD (données nominatives en production) · hébergement école.
Livrables : prototype, architecture, modèle de données, stratégie d'import, documentation, guide utilisateur.

MISE EN ŒUVRE

Une chaîne de traitement des données, de bout en bout

Fichier
.xls · .xlsx · .csv

›

Lecture
tout en texte : codes et zéros préservés

›

Mapping
configurable, profils en base

›

Contrôles
conversions, anomalies

›

PostgreSQL
modèle normalisé

›

API JSON
PHP

›

Interface
HTML / JavaScript

Règles métier paramétrées

Validation retenue, seuil d'heures, départements, mots-clés : stockés en base et appliqués dans **une seule vue SQL**. On les modifie sans toucher au code.

Import idempotent

Clé **(année, N° de convention)** : réimporter met à jour, sans créer de doublon. Toutes les conventions sont importées, et le filtre s'applique au calcul.

Environnement reproductible

PHP et PostgreSQL dans **Docker**, code versionné avec Git : l'outil se déploie tel quel sur un serveur de l'école.

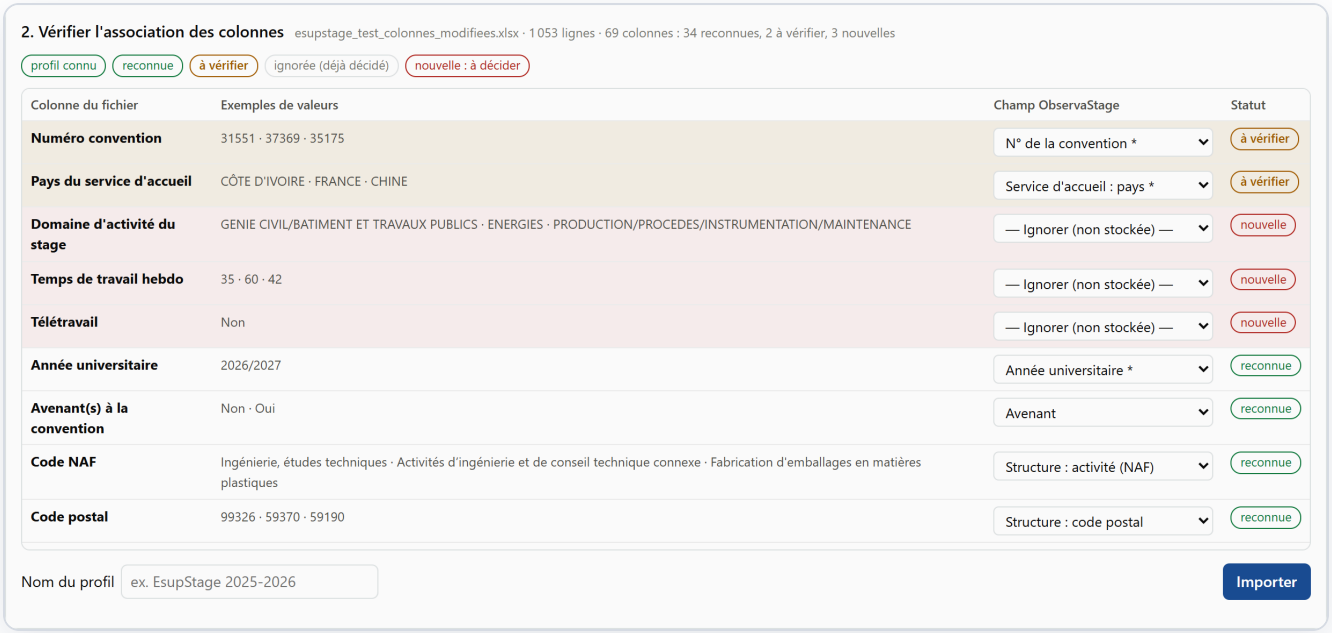
Modèle de données · **Métier** : étudiant (n° seulement) – stage – structure d'accueil – formation (code étape → niveau, spécialité) · **Import** : profils et règles de mapping, lots, anomalies · **Paramètres** : règles métier, référentiels

POINT TECHNIQUE 1

Le mapping configurable : seules les différences sont à traiter

1. **Profil connu** : même ensemble de colonnes qu'un import précédent → appliqué directement
2. **Colonne déjà rencontrée** : la décision passée est reprise
3. **Alias** : intitulés connus, comparés après normalisation (accents, casse, ponctuation)
4. **Similarité** (mots communs, distance entre chaînes) → proposition **« à vérifier »**

L'utilisatrice valide en voyant des **valeurs d'exemple**. Son choix devient un profil réutilisable. Une colonne ignorée n'est **jamais stockée**.



Fichier de test : colonnes renommées, déplacées, ajoutées, supprimées → **34 reconnues, 2 à vérifier, 3 nouvelles** sur 69

POINT TECHNIQUE 2

Des indicateurs fiables, des données protégées

Règles explicites, validées

- Conventions **validées** seulement
- Étranger = pays du **lieu du stage**
- Hauts-de-France = départements 02, 59, 60, 62, 80
- Valeurs aberrantes **signalées et exclues**, jamais corrigées

Validation croisée

Un script Python indépendant recalcule les indicateurs à partir du fichier brut, puis les compare à l'application.

48 / 48

indicateurs identiques

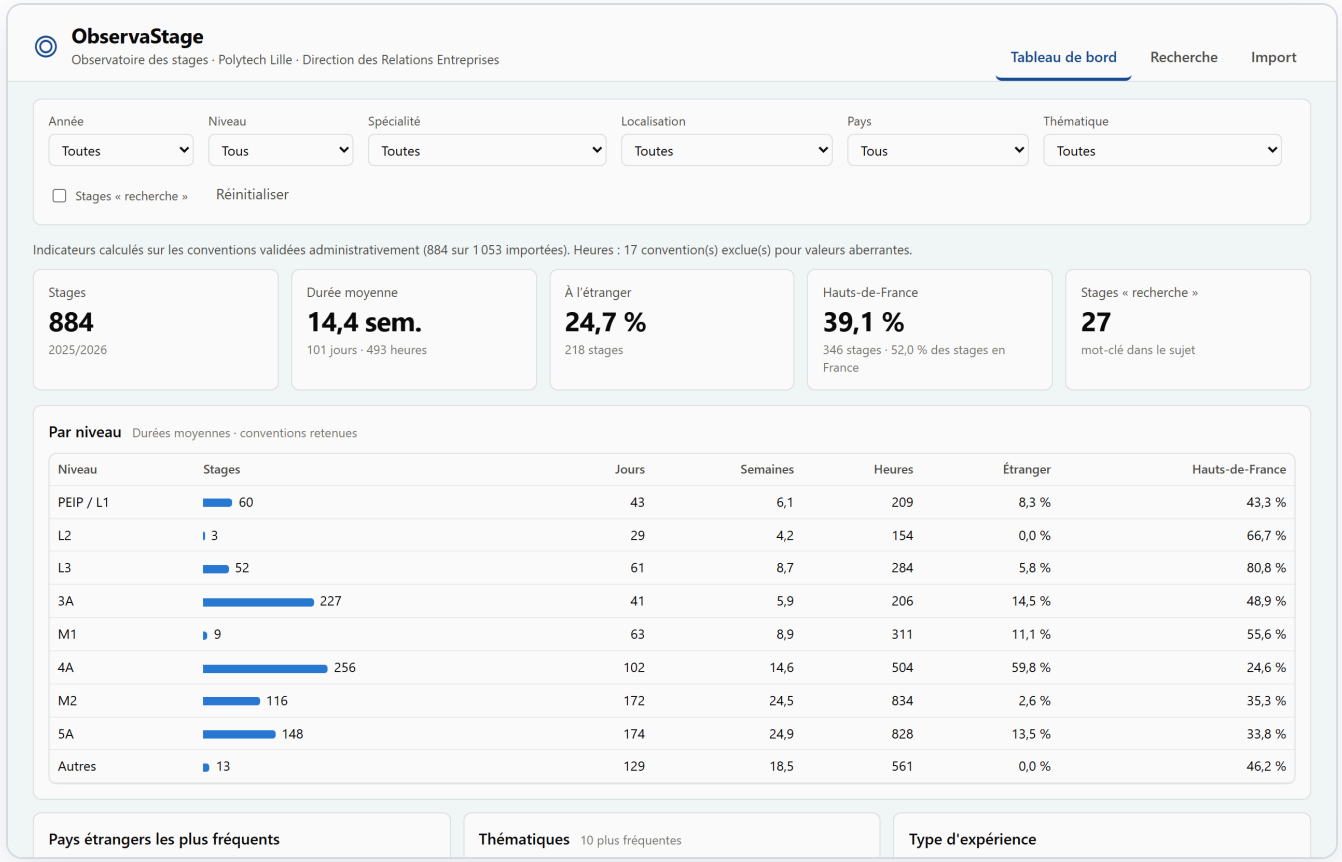
ex. 884 stages validés · 14,4 semaines en moyenne · 24,7 % à l'étranger

RGPD dès la conception

- Développement sur une base **anonymisée**, même code en production
- Colonnes ignorées **non stockées**, fichier supprimé après import
- Adresses, téléphones, e-mails personnels : **non stockés**
- Noms accessibles à la seule utilisatrice habilitée : **authentification**, hébergement école

DÉMONSTRATION

L'ébauche : du fichier EsupStage au tableau de bord



Déjà fonctionnel sur la base réelle anonymisée :

- Import des 1 053 conventions en ≈ 3 s, rapport d'anomalies
- Tableau de bord filtrable
- Recherche multicritère et par mots-clés
- Export CSV et XLS

Pas encore : authentification, écrans de paramètres, rapprochement des structures, graphiques avancés.

GESTION DE PROJET

Avancement et difficultés

14/09 — Lancement

28/09 — Cadrage tripartite

29/09 — Réunion technique : architecture, stack

S41-S42 — Analyse de la base anonymisée

12/10 — DRE : 14 règles métier, périmètre V1

S42-S43 — Conception et ébauche

Organisation

- Trello partagé, mail récapitulatif hebdomadaire
- Préparation et compte rendu de chaque réunion
- Git, Docker, chiffres de référence automatisés

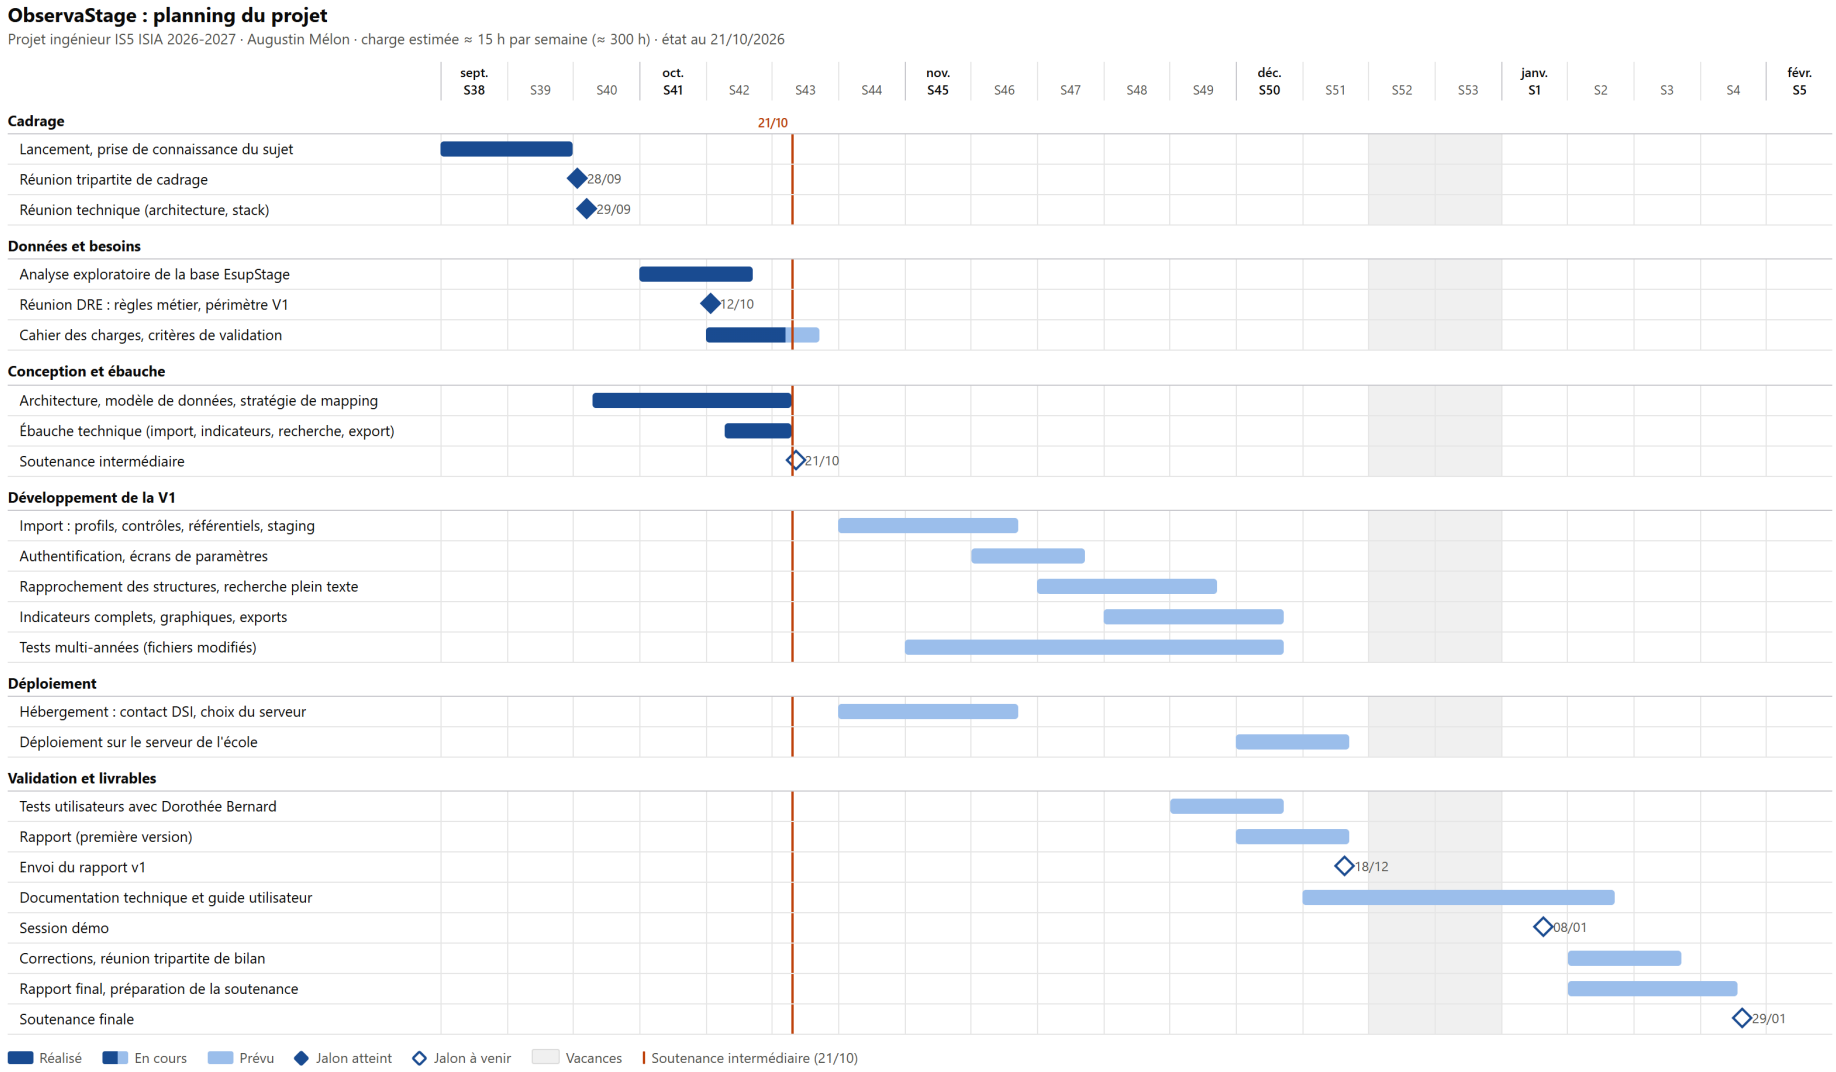
Difficultés

- **Accès aux données** : base complète début octobre, colonne utile en clair le 15/10
- **Aucun historique** pour tester l'évolution des colonnes
- **Données peu propres**, règles implicites à expliciter une par une

État au 21/10 : conception stabilisée, règles métier validées, ébauche fonctionnelle de bout en bout (import → export). **En avance** sur le calendrier initial, qui prévoyait le module d'import en S45-S48.

PLANNING

Diagramme de Gantt (≈ 15 h par semaine, 300 h)



SUITE DU PROJET

Recadrage, prochaines étapes et positionnement

Recadrage

- **À la hausse** : l'ébauche est en avance → recherche plein texte, rapprochement des structures, graphiques, historique
- **À la baisse** : type d'expérience partiel (texte libre, 164 conventions ; « stage » par défaut)

Prochaines étapes

- Faire valider les critères et la table des niveaux (S43)
- Consolider l'import, ajouter l'authentification (S44-S47)
- **Contacter la DSI pour l'hébergement** (principal risque)
- Tests avec la DRE avant la démo du 08/01

COMPÉTENCES ISIA

Data engineer

Le cœur du projet est un **pipeline d'ingestion** robuste :

- données hétérogènes dont le **schéma évolue**
- **mapping** vers un modèle cible, ETL
- **qualité** et traçabilité des données
- modélisation relationnelle, conformité **RGPD**

Avec une part d'ingénierie logicielle (API, interface) et d'analyse de données (indicateurs avec le métier).

Merci

Questions ?

Augustin Mélon · IS5 ISIA · ObservaStage

