ObservaStage

Valoriser et suivre les données de stages de Polytech Lille

Augustin Mélon · ISIA5 · Projet ingénieur 2026-2027

Soutenance intermédiaire · 21 octobre 2026

Référente : Dorothée Bernard (Direction des Relations Entreprises)

Tutrice école : Marie-Éléonore Kessaci · Expert technique : Bastien Cazaux



CONTEXTE

Des données de stages riches… mais inexploitables

- La **Direction des Relations Entreprises** gère les conventions de stage de **toutes les formations** (PEIP, licences, masters, cycle ingénieur)
- Depuis 2025-2026, tout passe par **EsupStage**, l'outil national de gestion des conventions
- EsupStage gère une convention… mais **n'analyse pas l'ensemble** : la seule sortie est un fichier Excel de 71 colonnes par année
- Bénéficiaires potentiels : direction (indicateurs, contrôles), enseignants (thématiques), futurs stagiaires (structures d'accueil)

80 %

des questions posées à la DRE sur les stages restent **sans réponse**

30 min

de traitement manuel pour chaque extraction, pour les autres

1 053

conventions en 2025-2026 · une seule personne pour les gérer

LE BESOIN

Comprendre le besoin : des questions aux règles

Question posée à la DRE	Ce qu'il fallait préciser	Règle validée
« Combien de stages ? »	Toutes les conventions ?	**Validées ; seuls les doublons non validés sont retirés**
« Combien à l'étranger ? »	Pays du siège ou du lieu du stage ?	**Pays du service d'accueil**
« Quelle part en Hauts-de-France ? »	Aucune colonne région	**Département du code postal**
« Quelle durée moyenne ? »	Dates ou heures déclarées ?	**En jours, semaines et heures**
« Combien dans la recherche ? »	Aucune colonne dédiée	**Mots-clés dans le sujet**

Chaque règle est **chiffrée** sur les données réelles, puis présentée à l'utilisatrice avec les options possibles avant d'être retenue.

Une démarche avec l'utilisatrice

- **3 réunions** avec la DRE : cadrage (28/09), règles métier (12/10), validation (19/10)
- Chaque réunion **préparée** (questions, options chiffrées) et suivie d'un **compte rendu**
- **14 règles** explicitées et validées, **périmètre priorisé** avec elle
- **Critères de validation** du prototype validés le 19/10

OBJECTIF

Un outil pour importer, structurer et exploiter

Importer

lire le fichier EsupStage de l'année, associer les colonnes, pré-traiter (contrôles, anomalies)

›

Structurer

une base de données historisée, année après année

›

Exploiter

indicateurs, recherche, export

Utilisatrice de la V1

Dorothée Bernard (DRE), **non informaticienne**. Elle doit pouvoir importer chaque année sans aide.

Plus tard : enseignants, étudiants (avec des droits adaptés).

Une chaîne qui s'adapte

Le format de l'extraction **peut changer d'une année à l'autre** : colonnes renommées, déplacées, ajoutées, supprimées.

→ **Tout s'ajuste par paramétrage** (colonnes, règles métier, référentiels), sans modifier le code.

LES DONNÉES

Pourquoi un import « naïf » ne suffit pas

Des intitulés trompeurs

Tirets, apostrophes et casse varient dans un même fichier :

`Service d'accueil - Commune`

`Service d’accueil – Adresse`

« Code NAF » contient… un libellé :

`Ingénierie, études techniques`

Des informations à dériver

Pas de colonne niveau, région, secteur ou recherche. Le niveau et la spécialité sont fusionnés :

`2an Ing Polytech Génie civil` → `4A · Génie civil`

Particularité de la base : pas de SIRET pour les structures étrangères (21 %), c'est normal. Il faut une autre clé pour les rapprocher.

Une qualité hétérogène

- **18 %** de cellules vides, 7 colonnes entièrement vides
- Valeurs aberrantes : jusqu'à **175 h** par semaine
- Type d'expérience (CDD, intérim) : seulement en **texte libre**

Aucun historique

2025-2026 est la **première année** d'EsupStage : impossible de tester l'évolution des colonnes sur des données réelles.

→ fichiers de test modifiés à partir de la base réelle

CAHIER DES CHARGES

Périmètre de la V1, priorisé avec la DRE

Indispensable	Import avec **mapping configurable** et profil réutilisable · contrôles et rapport d'anomalies · indicateurs (durée en jours, semaines et heures ; France / étranger ; Hauts-de-France ; par niveau, spécialité, année) · recherche multicritère · **export CSV et XLS**
Souhaitable	Historique multi-années · recherche plein texte · graphiques · rapprochement des structures sans SIRET
Bonus	Indicateurs « recherche » et « secteur » · type d'expérience (CDD, intérim, bénévolat)
Hors V1	Gratification · gestion de plusieurs profils

Critères de validation (validés le 19/10)

1. **Import** autonome, adapté aux colonnes modifiées, sans doublon au réimport
2. **Indicateurs** identiques aux chiffres de référence
3. **Recherche** par année, niveau, spécialité, lieu, thématique
4. **Export** CSV et XLS lisible dans Excel

Contraintes : technologies imposées par l'école (PHP, JavaScript, PostgreSQL) · RGPD (données nominatives en production) · hébergement école.
Livrables : prototype, architecture, modèle de données, stratégie d'import, documentation, guide utilisateur.

MISE EN ŒUVRE

Une chaîne de la donnée, adaptable de bout en bout

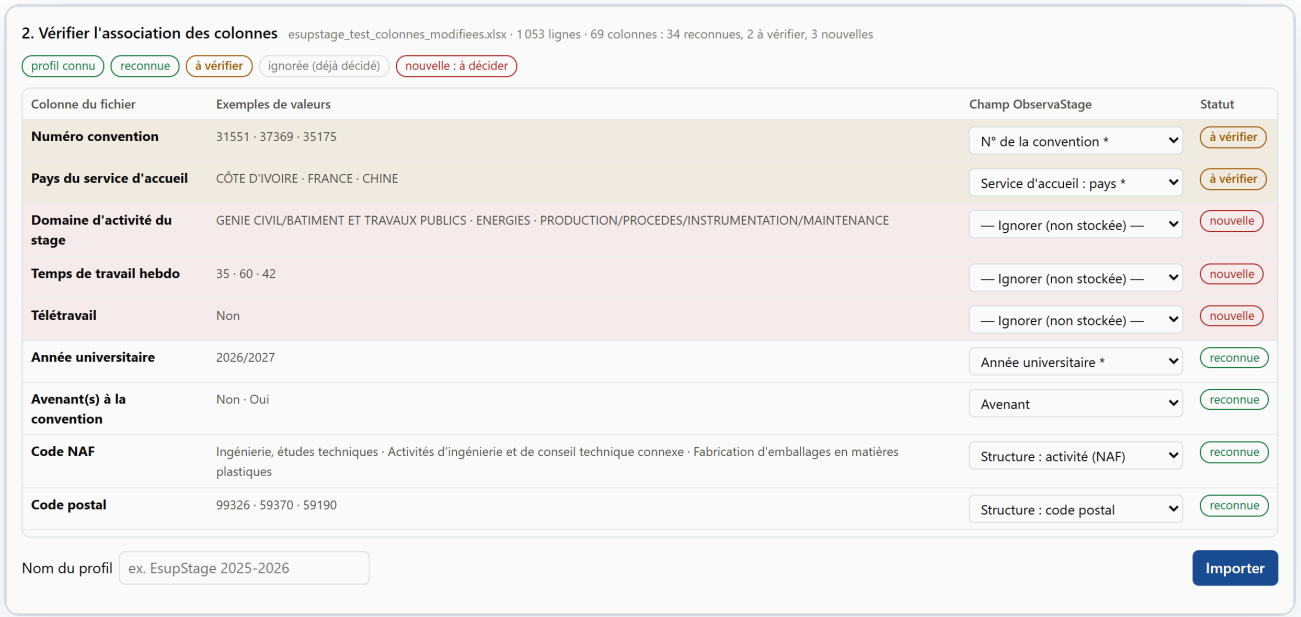


Technologies **imposées par l'école** (standard des applications de Polytech), validées avec l'expert technique le 29/09.

Mapping : seules les différences sont à traiter

1. **Profil connu** : mêmes colonnes qu'un import précédent → appliqué
2. **Colonne déjà rencontrée** : décision passée reprise
3. **Alias** connus, après normalisation (accents, casse, ponctuation)
4. **Similarité** → proposition **« à vérifier »**

L'utilisatrice valide en voyant des **valeurs d'exemple** ; son choix devient un profil réutilisable.



2. Vérifier l'association des colonnes — esupstage_test_colonnes_modifiees.xlsx · 1 053 lignes · 69 colonnes : 34 reconnues, 2 à vérifier, 3 nouvelles

profil connu | reconnue | à vérifier | ignorée (déjà décidé) | nouvelle : à décider

Colonne du fichier	Exemples de valeurs	Champ ObservaStage	Statut
Numéro convention	31551 · 37369 · 35175	N° de la convention *	à vérifier
Pays du service d'accueil	CÔTE D'IVOIRE · FRANCE · CHINE	Service d'accueil : pays *	à vérifier
Domaine d'activité du stage	GENIE CIVIL/BATIMENT ET TRAVAUX PUBLICS · ENERGIES · PRODUCTION/PROCEDES/INSTRUMENTATION/MAINTENANCE	— Ignorer (non stockée) —	nouvelle
Temps de travail hebdo	35 · 60 · 42	— Ignorer (non stockée) —	nouvelle
Télétravail	Non	— Ignorer (non stockée) —	nouvelle
Année universitaire	2026/2027	Année universitaire *	reconnue
Avenant(s) à la convention	Non · Oui	Avenant	reconnue
Code NAF	Ingénierie, études techniques · Activités d'ingénierie et de conseil technique connexe · Fabrication d'emballages en matières plastiques	Structure : activité (NAF)	reconnue
Code postal	99326 · 59370 · 59190	Structure : code postal	reconnue

Nom du profil — ex. EsupStage 2025-2026 — Importer

Fichier de test aux colonnes modifiées : **34 reconnues, 2 à vérifier, 3 nouvelles** sur 69

FIABILITÉ

Des indicateurs fiables, des données protégées

Règles explicites, validées

- Conventions **validées** ; doublons non validés retirés (décidé le 19/10)
- Étranger = pays du **service d'accueil**
- Hauts-de-France = départements 02, 59, 60, 62, 80
- Valeurs aberrantes **signalées et exclues**, jamais corrigées

Vérification croisée

Un script Python indépendant recalcule les indicateurs à partir du fichier brut, puis les compare à l'application.

48 / 48

indicateurs identiques

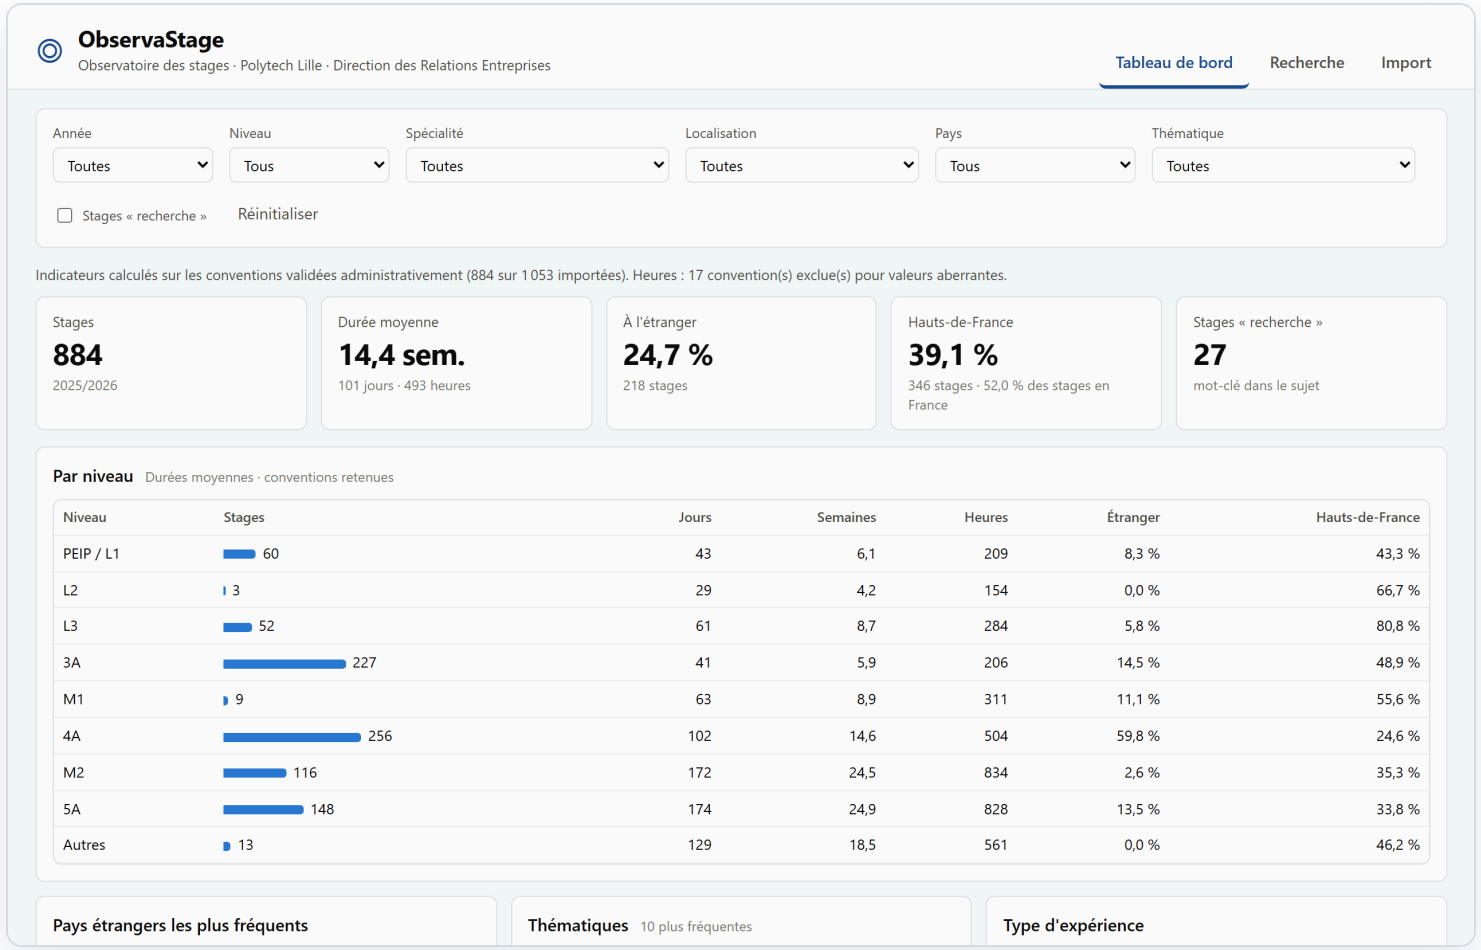
ex. 884 stages validés · 14,4 semaines en moyenne · 24,7 % à l'étranger

RGPD dès la conception

- Développement sur une base **anonymisée**, même code en production
- Colonnes ignorées **non stockées**, fichier supprimé après import
- Adresses, téléphones, e-mails personnels : **non stockés**
- Noms accessibles à la seule utilisatrice habilitée : **authentification**, hébergement école

DÉMONSTRATION

La V1 : du fichier EsupStage au tableau de bord



ObservaStage
Observatoire des stages · Polytech Lille · Direction des Relations Entreprises

Tableau de bord | Recherche | Import

Année: Toutes | Niveau: Tous | Spécialité: Toutes | Localisation: Toutes | Pays: Tous | Thématique: Toutes

☐ Stages « recherche » Réinitialiser

Indicateurs calculés sur les conventions validées administrativement (884 sur 1 053 importées). Heures : 17 convention(s) exclue(s) pour valeurs aberrantes.

Stages	Durée moyenne	À l'étranger	Hauts-de-France	Stages « recherche »
884	**14,4 sem.**	**24,7 %**	**39,1 %**	**27**
2025/2026	101 jours · 493 heures	218 stages	346 stages · 52,0 % des stages en France	mot-clé dans le sujet

Par niveau Durées moyennes · conventions retenues

Niveau	Stages	Jours	Semaines	Heures	Étranger	Hauts-de-France
PEIP / L1	60	43	6,1	209	8,3 %	43,3 %
L2	3	29	4,2	154	0,0 %	66,7 %
L3	52	61	8,7	284	5,8 %	80,8 %
3A	227	41	5,9	206	14,5 %	48,9 %
M1	9	63	8,9	311	11,1 %	55,6 %
4A	256	102	14,6	504	59,8 %	24,6 %
M2	116	172	24,5	834	2,6 %	35,3 %
5A	148	174	24,9	828	13,5 %	33,8 %
Autres	13	129	18,5	561	0,0 %	46,2 %

Pays étrangers les plus fréquents | **Thématiques** 10 plus fréquentes | **Type d'expérience**

Déjà fonctionnel sur la base réelle anonymisée :

- Import des 1 053 conventions en ≈ 3 s, rapport d'anomalies
- Tableau de bord filtrable
- Recherche multicritère et par mots-clés
- Export CSV et XLS

Avant la mise en service : authentification, écrans de paramètres, règle des doublons.

GESTION DE PROJET

Une démarche itérative, validée à chaque étape

14/09 — Lancement

28/09 — Cadrage tripartite

29/09 — Réunion technique : architecture

S41-S42 — Analyse des données

12/10 — DRE : règles métier, périmètre

S42-S43 — Conception et V1

19/10 — DRE : critères validés · soutenance blanche

Organisation

- Trello partagé, **mail récapitulatif** hebdomadaire
- Réunion = **préparation** (décisions à prendre, options chiffrées) → **compte rendu** → actions
- Périmètre **priorisé** : je coupe dans le souhaitable, jamais dans l'indispensable
- Risques suivis : hébergement, format des futures extractions

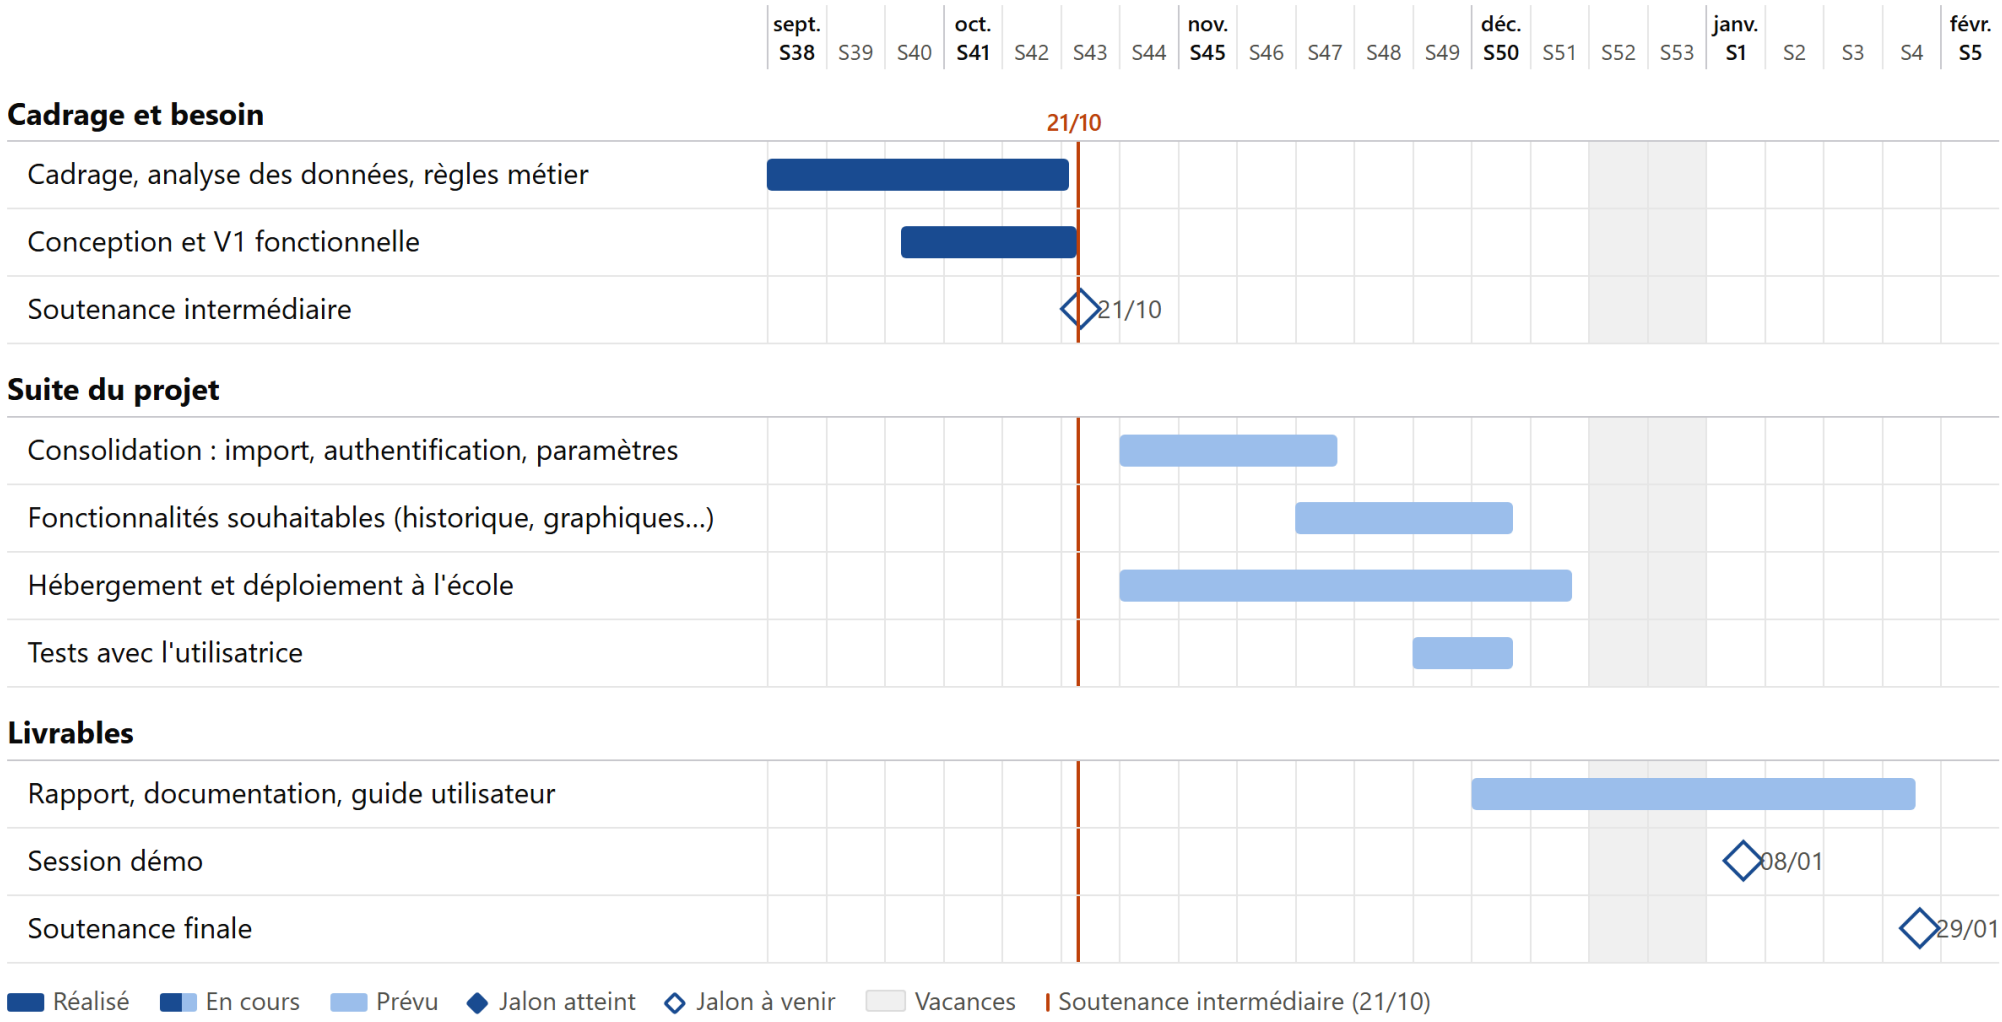
Difficultés

- **Accès aux données** : base complète début octobre, colonne utile en clair le 12/10
- **Aucun historique** pour tester l'évolution des colonnes
- **Règles implicites** à expliciter une par une avec la DRE

État au 21/10 : règles métier et critères validés, **V1 fonctionnelle** de bout en bout (import → export). **En avance** : le calendrier initial prévoyait le module d'import en S45-S48.

PLANNING

Planning : la V1 est prête, place à la consolidation



USAGE DE L'IA

Claude Code : un assistant cadré et vérifié

1. Cadrer avant

- Un **fichier de contexte** tenu à jour : règles validées, contraintes RGPD, pièges des données
- Les **décisions sont prises avant le code**, avec la DRE et l'expert technique
- **Une tâche à la fois** ; l'IA expose son plan et ses questions avant d'agir

2. Vérifier après

- Chiffres : **deux calculs indépendants** (Python et SQL), 48 / 48
- Chaque modification **relue** avant d'être enregistrée (Git)
- Tests sur la base réelle et sur les fichiers modifiés

3. Garder la main

- L'IA ne voit que la base **anonymisée** ; les analyses ne sortent que des agrégats
- Règles métier, validation, envoi des mails : **c'est moi**
- Les résultats sont confrontés à l'utilisatrice

> « Voici les retours des deux réunions […]. Dis-moi ce que tu vas faire et pose-moi des questions avant de faire quoi que ce soit. »

Le temps gagné sur l'écriture du code et des documents est réinvesti dans la **compréhension du besoin** et la **vérification**.

SUITE DU PROJET

Recadrage, prochaines étapes et positionnement

Recadrage

- **À la hausse** : la V1 est en avance → recherche plein texte, rapprochement des structures, graphiques, historique
- **À la baisse** : type d'expérience partiel (texte libre, 164 conventions ; « stage » par défaut)

Prochaines étapes

- Règle des doublons, rapport d'import enrichi, authentification (S44-S47)
- **Contacter la DSI pour l'hébergement** (principal risque)
- Tests avec la DRE avant la démo du 08/01

COMPÉTENCES ISIA

Data engineer

Le cœur du projet est la **chaîne complète de la donnée**, du fichier brut à l'indicateur :

- **ingestion** de données dont le schéma évolue, mapping
- **pré-traitement**, qualité et traçabilité
- **modélisation** relationnelle, règles métier, RGPD
- **exploitation** : indicateurs, recherche, export

Avec une part d'ingénierie logicielle (API, interface) et un travail continu avec le métier.

Merci

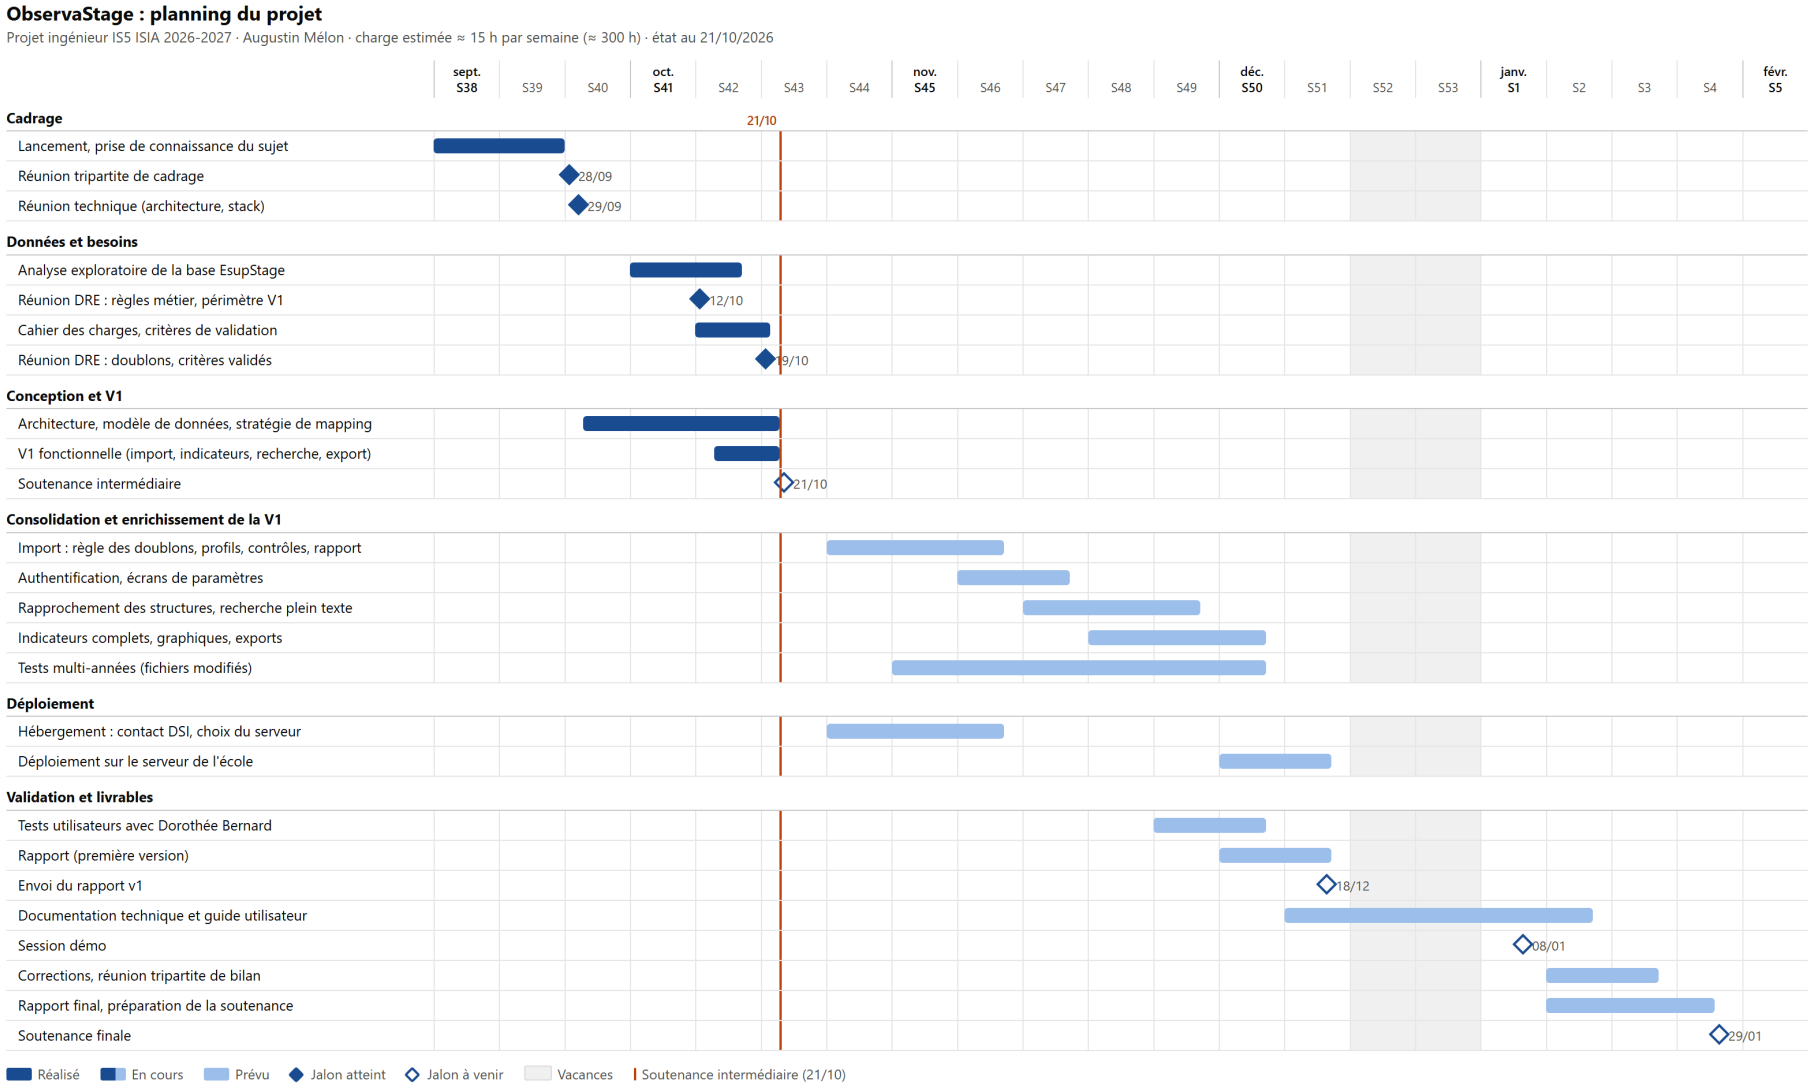
Questions ?

Augustin Mélon · ISIA5 · ObservaStage



ANNEXE

Diagramme de Gantt détaillé



ANNEXE

Architecture détaillée

Fichier
.xls · .xlsx · .csv

›

Lecture
tout en texte : codes et zéros préservés

›

Mapping
configurable, profils en base

›

Pré-traitement
conversions, anomalies

›

PostgreSQL
modèle normalisé

›

API JSON
PHP

›

Interface
HTML / JavaScript

Règles métier paramétrées

Validation retenue, seuil d'heures, départements, mots-clés : stockés en base et appliqués dans **une seule vue SQL**. On les modifie sans toucher au code.

Import idempotent

Clé **(année, N° de convention)** : réimporter met à jour, sans créer de doublon. Toutes les conventions sont importées, et le filtre s'applique au calcul.

Environnement reproductible

PHP et PostgreSQL dans **Docker**, code versionné avec Git : l'outil se déploie tel quel sur un serveur de l'école.

Modèle de données · **Métier** : étudiant – stage – structure d'accueil – formation (code étape → niveau, spécialité) · **Import** : profils et règles de mapping, lots, anomalies · **Paramètres** : règles métier, référentiels